
Examen de Redes Tercer Parcial

Universidad Tecnológica de la Mixteca

Redes Neuronales

Comportamiento de una red convolucional base y
la optimización de los parámetros de la misma
mediante algoritmos genéticos Jairo Isaac Muñoz López

2020170203

Octavo semestre

Huajuapán de León, Oaxaca, México a 28 de abril de 2026.

Índice general

0.1. Introducción	4
0.2. Red Neuronal Base	4
0.3. Uso de algoritmo genético	4
0.4. Comparación	6

0.1. Introducción

Los algoritmos genéticos nos són útiles para realizar una adecuada optimización en los parámetros de redes neuronales.

En esta ocasión utilizamos algoritmos genéticos para optimizar lo parámetros de una red neuronal convolucional con la que pretendemos hacer una clasificación y reconocimiento de imagenes en el conjunto Fashion-Mnist. Esta base de datos cuenta con un total de 70,000 imágenes en blanco y negro y está cargada directamente en la biblioteca de Keras.

0.2. Red Neuronal Base

Entre las bibliotecas necesarias que utilizamos las siguientes:

- `tensorflow`
- `keras.models import Sequential`
- `keras.layers import Dense, Flatten, Conv2D, MaxPool2D, Dropout`
- `keras import datasets`

Después de hacer un pre procesamiento de los datos, precedimos a construir la red neuronal convolucional. Nuestra red recibe como datos de entrada imagenes de 28x28. Cuenta con 2 capas convolucionales, la primer capa convolucional presenta un kernel de 3x3, con una activación 'relu' y 32 filtros. Mientras que la segunda capa convolucional difiere de un total de 64 filtros comparados con los 32 de la primer capa. Tambien se presentan dos capas de pooling de tamaño 2x2. Una capa densa con 128 neuronas y función de activación 'relu'. Además de que se empleó una capa de aplanamiento.

Al realizar el entrenamiento utilizamos un learning rate de 0.001. Utilizamos un total de 23 épocas y un batch size de 128


Se hizo un registro de la mejora del accuracy para poder graficar el progreso de la red a través de las épocas. y al emplear el modelo en el conjunto de prueba se obtuvo un accuracy de 0.93

0.3. Uso de algoritmo genético

A diferencia del algoritmo base, aquí se muestran tres partes esenciales: la estructura del genoma (`gene_space`), la función de decodificación (`decode_chromosome`) y la función de aptitud (`fitness_function`).

En `gene_space` se establecen los parámetros a optimizar en nuestra red. En este caso fueron:

- `learning_rate`
- `filter_size_1`



- `filter_size_2`
- `activation_function`
- `kernel_size_conv`
- `kernel_size_pool`
- `stride_conv`
- `stride_pool`
- `dense_neurons`
- `dropout_rate`

La función de `decode_chromosome` nos permite convertir la información genética en un formato legible y adecuado para la estructura de la red se encarga de convertir números a cadenas de texto con el nombre de funciones de activación, puntos flotantes en enteros entre otras cosas, respetando siempre los rangos para el `gene_space`

por último, la función `fitness` se encarga de entrenar cada individuo existente por generación, y mide su aptitud utilizando el `accuracy`

Utilizamos un total de 6 generaciones y poblaciones de tamaño 10, a cada individuo se le permitió mejorar durante cinco épocas y utilizar lotes de 32 imágenes.

Una vez que el algoritmo genético finalizó, reconstruimos la red utilizando los parámetros obtenidos para la estructura que obtuvo el mejor fitness (0.82) y posteriormente probamos el modelo en el conjunto de prueba, obteniendo un `accuracy` de 0.85




Figura 1: Progreso por generación

0.4. Comparación

Como se puede apreciar en el fitness o el accuracy, en el modelo base se obtuvo un accuracy significativamente más alto que el obtenido en el modelo optimizado. $0,92 > 0,85$ esto puede deberse principalmente a que al algoritmo genético no se le dió mucho por explorar, pues las generaciones fueron sólo 6, y para cada individuo sólo se le permitían 5 generaciones, además algunos parámetros tenían rangos muy amplios, como el número de neuronas en ciertas capas, las cuales iban de 1 neurona a las 128 neuronas. Probablemente si se le permiten ciertos cambios al algoritmo genético, y si se usa un equipo de cómputo con mejor rendimiento, obtendríamos mejores resultados.